KTDB 교통 데이터베이스 구축 요약 보고서

— 토목 설계엔지니어를 위한 DB 구축 타당성 가이드

항목	내용
문서명	KTDB 교통 데이터베이스 구축 요약 보고서
작성일	2026-03-23
대상 독자	토목·교통 분야 설계엔지니어 (비개발직)
작성 목적	KTDB 데이터의 DB 구축 가능성 판단 및 방법론 요약

1. 왜 데이터베이스가 필요한가

현재 KTDB 데이터 활용 업무는 **ZIP 다운로드 → Excel 수작업 분석 → 보고서 작성** 과정을 거칩니다.

문제	구체적 상황
파일이 너무 많다	ZIP 25건, 내부 파일 수백 개
포맷이 제각각	Excel(.xlsx)과 텍스트(.OUT, .TXT) 혼재, 권역마다 다름
데이터 양이 방대	전체 약 **9,300만 행** (Excel 한계 100만 행 초과)
수단 명칭이 권역마다 다름	같은 "지하철"이 지하철, 도시철도 등으로 표기
합계 행 이중 계산 위험	"합계" 행이 포함되어 SUM 시 2배 오류 발생 가능

DB를 구축하면 **자동 파싱·정제 → 통합 저장 → AI 자연어 질의 → 5초 내 결과**가 가능합니다.

---

2. KTDB 원본 데이터 개요

2.1 데이터 분류

대분류	소분류	설명	ZIP 수
여객(PSN)	목적별(OBJ)	출근·등교·업무·귀가·기타별 통행량	7건
여객(PSN)	수단별(MOD-1x)	승용차·버스·철도 등 수단별 통행량	7건
여객(PSN)	접근수단 등(MOD-2x)	철도역 접근수단, 목적×수단 OD	7건
화물(FRE)	자동차(CAR)	소·중·대형 화물차 톤급별 통행량	1건

2.2 권역별 파일 형태 차이 (핵심 난제)

같은 종류의 데이터인데도 **권역에 따라 파일 형태가 완전히 다릅니다.**

구분	전국 250존	비수도권 5개 권역	수도권
파일 포맷	Excel (.xlsx)	Excel (.xlsx)	**텍스트 (.OUT, .TXT)**
인코딩	UTF-8	UTF-8	**CP949 (한글 전용)**
헤더(열 이름)	있음	있음	**없음**
존코드 형태	정수 1~250	정수 1~N	**7자리 문자열**
파생 컬럼	없음	있음 (승용차/택시 합산 등)	없음

2.3 데이터 규모

데이터 종류	예상 행 수
전국 250존 여객 OD	약 87만 행
비수도권 권역별 OD	약 1,850만 행
수도권 OD	**약 7,200만 행 (전체의 77%)**
화물 OD + 사회경제지표 + 기타	약 200만 행
합계	**약 9,300만 행**

---

3. 핵심 개념 이해

3.1 존(Zone) 체계

KTDB는 행정구역을 번호 체계로 관리합니다.

```
17존 (시도)        예: 1=서울, 2=부산, ... 17=제주
  └─ 250존 (시군구)   예: 1=종로구, 2=중구, ...
       └─ 소존 (읍면동)   수도권 1,310개, 비수도권 권역별 수백 개
```

- 비수도권 소존 번호는 **권역마다 1번부터 시작** → 권역코드 + 소존번호를 함께 써야 구분 가능

3.2 OD 데이터

OD(Origin-Destination) = 출발지→도착지 통행량. 원본은 행렬(매트릭스) 형태이지만, DB에서는 검색에 유리한 **세로형(롱폼)** 으로 변환하여 저장합니다.

```
[원본 엑셀: 행렬]                [DB: 세로형]
      도착1  도착2 ...            출발존 | 도착존 | 연도 | 승용차 | 버스
출발1  100    200 ...              1   |   1   | 2023 |  100  | 200
출발2  300     50 ...              1   |   2   | 2023 |  300  |  50
```

3.3 수단 분류 체계의 차이

같은 교통수단이 권역마다 다른 이름으로 표기되는 것이 가장 까다로운 문제입니다.

교통수단	전국 250존	비수도권	수도권
도시철도	지하철	도시철도	열 이름 없음
일반+고속철도	분리 제공	일반/고속철도 (합산)	열 이름 없음
도보+자전거	없음	도보/자전거	열 이름 없음
택시	없음	택시	열 이름 없음
항공·해운	분리 제공	없음 (기타에 포함 추정)	불명

해결: DB에 "동의어 매핑 테이블"을 만들어 "지하철=도시철도" 자동 변환.

3.4 파생 행(합계) 이중 계산 문제

원본에 "합계" 행이 원본 행과 함께 있어 SUM 시 **2배 오류** 발생.

```
출근:  100  ← 원본        해결: 모든 행에 is_derived(파생여부) 표시.
등교:   50  ← 원본              AI 분석 뷰에서 원본만 자동 필터.
합계:  150  ← 파생값
SUM = 300  ← ❌ (정답은 150)
```

---

4. 구축된 DB의 전체 구조

4.1 데이터 처리 흐름

```
[KTDB ZIP 25건] → [자동 파싱·정제] → [PostgreSQL DB 약 9,300만 행] → [AI 자연어 질의] → [즉시 결과]
```

4.2 테이블 구성

종류	테이블 수	역할	행 수
참조 테이블	6개	코드의 이름·속성 관리	수십 행
존체계 테이블	3개	존 번호 ↔ 행정구역명 매핑	~3,800행
OD 테이블	**10개**	**핵심 통행량 데이터**	**~9,200만 행**
사회경제지표	6개	인구·종사자수·학생수 등	~16만 행
운영 테이블	2개	데이터 적재 이력 관리	수백 행

4.3 테이블 간 관계

```
[참조 테이블: 권역코드, 연도, 목적코드, 수단코드]
        │ (코드 참조)
[존체계 테이블]  ← "종로구는 250존 1번" 같은 매핑 정보
        │ (존번호로 연결)
[OD 테이블]  ← "1번 존 → 34번 존, 출근, 100통행/일"
        │ (같은 존번호로 연결)
[사회경제지표]  ← "1번 존, 2023년, 총인구 = 123,456명"
```

4.4 대용량 처리: 파티셔닝

대용량 테이블을 연도 또는 권역 기준으로 **물리적으로 분할**하여 조회 성능을 확보합니다.

테이블	파티션 기준	파티션 수	효과
수도권 OD 3종	연도	각 7개	1,200만~4,800만 행 → 연도별 170만~690만 행만 스캔
비수도권 OD 2종	권역	각 5개	권역별 분리 조회
전국 250존 OD 3종	연도(RANGE)	각 7개	"2023~2030년" 범위 조회 최적화

5. AI(자연어 질의) 연동

5.1 작동 원리

```
사용자: "2023년 서울에서 부산으로 출근 통행량은?"
    ↓
AI가 SQL 자동 생성 → DB 실행 → 결과 반환
    ↓
"서울→부산 출근 통행량은 일평균 12,345통행(AAWDT 기준)입니다."
```

5.2 AI 전용 분석 뷰

AI는 원본 테이블을 직접 보지 않고, **"분석 뷰"** 를 통해서만 데이터에 접근합니다.

뷰	기능
목적OD/수단OD 뷰	합계 행 자동 제외 + 지역 이름 자동 연결
17존 집계 뷰	시도 수준 사전 집계 (즉시 응답)
지명 검색 뷰	"해운대구" → 존 번호 자동 검색
수단 매핑 테이블	"지하철=도시철도" 자동 변환

5.3 성능 목표

단계	목표 시간
AI SQL 생성	2~3초

단계	목표 시간
DB 쿼리 실행	1~2초
결과 포맷팅	0.3초
전체	**5초 이내**

---

6. 구축에 필요한 지식과 역할 분담

6.1 필요 지식

영역	난이도	설계엔지니어가 알아야 할 수준
KTDB 데이터 구조 (존체계, OD)	★★☆	어떤 데이터가 어디에 있는지 파악
수단 분류 체계 차이	★★★	같은 수단의 다른 이름 인지
데이터 단위 (AAWDT, 통행/일 vs 대/일)	★★☆	보고서 단위 정확 기재
SQL 기본	★★☆	AI가 대신 생성, 결과 해석만
PostgreSQL 운영	★★★★	**개발자 영역**
ETL 파이프라인	★★★★★	**개발자 영역**

6.2 역할 분담

역할	담당자	주요 업무
데이터 검증자	설계엔지니어	적재 데이터 검증, 분석 결과 해석
DB 구축자	개발자/DBA	PostgreSQL, DDL, ETL 파이프라인
AI 연동 개발자	개발자	Text-to-SQL, 뷰 레이어, 보고서 자동화
도메인 전문가	교통공학 전공자	수단 분류 검증, 분석 시나리오 정의

6.3 설계 결정이 필요한 사항

DB 구축 전에 **설계엔지니어의 판단이 필요한 항목**들입니다.

결정 사항	선택지	판단 이유
수단 분류 통합 여부	통합 정규화 / 원본 유지	전국 vs 권역 비교 가능성
파생 컬럼(승용차/택시 합산) 포함	제외(중복) / 포함(원본 보존)	합산값 직접 사용 여부
17존 피벗 시트 활용	요약 테이블 저장 / 무시	시도간 요약표 필요성
접근수단 OD 포함 범위	포함 / 1차 제외	접근수단 분석 우선순위
Excel 수식 셀 처리	캐시값 읽기 / 직접 계산	수식 오류 가능성
과거년도 데이터 포함	포함(버전 구분) / 최신만	과거 버전 비교 필요성

---

7. 한계점과 주의사항

7.1 데이터 한계

한계	영향	대응
수도권 TXT 열 이름 미제공	10개 수단 컬럼이 어떤 수단인지 공식 정의 없음	**설명자료(.hwp) 확인 선행 필수**
수도권 "업무" 목적 누락	업무 목적의 수단별 분석 불가	KTDB에 의도적 누락 여부 확인 필요
수단 분류 3종 혼재	전국 단위 완벽한 통합 비교 불가	동의어 매핑으로 부분 해결
사회경제지표 권역별 차이	인구 시트명이 `5-24세` vs `5-29세`로 다름	지표코드 매핑 규칙 정의 완료
화물 OD 컬럼명 오류	도착 17존 컬럼명이 출발과 동일	위치 기반 파싱으로 처리

> **보고서 작성 시 단위 주의**:
>
> - **재차인원**: 통행/일 → 대/일 환산 (예: 승용차 재차인원 1.3명 → 100통행은 약 77대)
> - **AADT 전환계수**: 주중 평균(AAWDT) → 연평균(AADT) 환산

7.2 기술적 한계

한계	영향
Azure PostgreSQL 스키마 제한	`public` 스키마에 `ktdb_` 접두사 사용
9,300만 행 초기 적재	수시간 소요 예상
Materialized View 갱신	데이터 변경 시 수동 REFRESH 필요

7.3 AI 한계

한계	대응
LLM 모델 미확정	모델-agnostic 설계로 유연성 확보
복잡한 다중 조건 질의 정확도 한계	정형 쿼리 템플릿 사전 정의
"수단별 OD"와 "접근수단 OD" 혼동 위험	접근수단 OD는 AI에 미노출

---

8. 구축 가능성 판단

8.1 결론: 구축 가능

조건	상태
원본 데이터 구조 파악	☑ 완료 (ZIP 25건 전체 분석)
DB 스키마 설계	☑ 완료 (25개 테이블 + ERD)

조건	상태
AI 연동 설계	☑ 완료 (뷰 레이어 + 쿼리 패턴)
수도권 TXT 수단 컬럼 확인	⚠ 미완료 (설명자료 확인 필수)
PostgreSQL 서버	☑ Azure PostgreSQL 준비
개발 인력 확보	❓ 확인 필요

8.2 기대 효과

지표	현재 (수작업)	목표 (DB+AI)	개선율
데이터 수집·가공 시간	~8시간	~30분	**93% 단축**
OD 쿼리 응답 시간	수분~수십분	**5초 이내**	즉시 응답
Text-to-SQL 정확도	N/A	핵심 쿼리 **90%+**	신규
보고서 작성 속도	기준	**2배 향상**	50% 단축

8.3 구축 로드맵

단계	주요 작업	예상 소요
Phase 1	DB 인프라 (DDL, 파티션, 뷰, 매핑 테이블)	1일
Phase 2	존체계 적재	0.5일
Phase 3	사회경제지표 적재	1일
Phase 4	전국 250존 OD 적재	1일
Phase 5	비수도권 권역별 OD 적재	1.5일
Phase 6	수도권 대용량 OD 적재 (최대 4,800만 행)	2일
Phase 7	AI 연동 준비 (MV 갱신, 권한, 테스트)	0.5일
합계		**약 7.5일**

용어 사전

용어	설명
KTDB	국가교통 데이터베이스. 국토교통부 운영 교통 데이터 플랫폼
OD	Origin-Destination. 출발지(O)→도착지(D) 간 통행량
AAWDT	연평균 **평일** 일통행량 (주말·공휴일 제외)
AADT	연평균 일통행량 (주말 포함)
존(Zone)	교통 분석용 행정구역 번호 체계

용어	설명
파티셔닝	대용량 테이블을 물리적으로 분할 저장하는 기법
뷰(View)	자주 쓰는 조회 조건을 미리 정의한 가상 테이블
ETL	Extract-Transform-Load. 데이터를 추출·변환·적재하는 과정
Text-to-SQL	자연어 질문을 SQL 질의로 자동 변환하는 AI 기술
is_derived	파생 행 표시. TRUE=합계 행, FALSE=원본 데이터
LLM	Large Language Model. 대규모 언어 모델
롱폼/와이드폼	세로형(한 행=하나의 값) / 행렬형(한 행=여러 값) 데이터 형태

작성: AX 팀 / 최종수정: 2026-03-23